LABORATORIO DE INGENIERÍA MÉDICA

Análisis de datos sintéticos mediante GitHub y Google Colab

Docente: JHONATTAN ALEXANDER CORDERO PAREJA

Estudiante: NICOL NIEVES MOLINA
Programa: Medicina
Asignatura: Ingeniería Médica
Código : 01260181096

1. Introducción

En este laboratorio se realizó un ejercicio de análisis de datos utilizando una base de datos compuesta por 200 registros sintéticos de pacientes. Para desarrollar la actividad se utilizaron GitHub, como plataforma de almacenamiento y organización de archivos, y Google Colab, como entorno para ejecutar código en Python.

A través de diferentes instrucciones se exploró la información, se verificó la calidad de los datos, se calcularon medidas estadísticas, se aplicaron filtros, se creó una variable derivada y se elaboraron representaciones gráficas. Finalmente, se generó un reporte automático con algunos de los resultados obtenidos.

El ejercicio permitió reconocer la utilidad de las herramientas digitales para organizar, procesar y describir información, teniendo presente que los datos utilizados son simulados y que sus resultados tienen únicamente fines educativos.

2. Resultados e interpretación de las misiones

Misión 2. Comprobar la conexión

¿Cuántas filas y columnas tiene la base de datos?

La base de datos contiene 200 filas y 12 columnas.

¿Qué representa una fila?

Cada fila representa un registro correspondiente a un paciente sintético. En cada registro se almacena información relacionada con su edad, sexo, peso, estatura, frecuencia cardíaca, presión sistólica, presión diastólica, saturación de oxígeno, temperatura, glucosa y servicio.

Por lo tanto, cada fila reúne los datos de un registro individual, mientras que las columnas representan las diferentes variables utilizadas para el análisis.

Misión 3. Calidad de los datos

¿Hay valores faltantes?

No se identificaron valores faltantes en ninguna de las 12 columnas de la base de datos. El resultado obtenido fue de cero valores ausentes en todas las variables.

¿Se repiten identificadores?

No se encontraron identificadores duplicados en la columna correspondiente al paciente. El resultado fue de cero registros repetidos.

Interpretación:

La revisión permitió comprobar que la base de datos no presenta valores faltantes ni identificadores duplicados. Esto facilita el desarrollo de los análisis posteriores, ya que no fue necesario realizar procedimientos de eliminación o corrección de registros por estas causas.

También se identificaron diferentes tipos de datos: variables de texto, como paciente, sexo y servicio; variables enteras, como edad, frecuencia cardíaca, presión arterial, saturación y glucosa; y variables decimales, como peso, estatura y temperatura.

Misión 4. Estadística descriptiva

¿Cuál es la edad promedio?

La edad promedio de los registros analizados fue de **52,4 años**. La edad mínima registrada fue de 18 años y la máxima de 88 años.

¿Qué variables tienen mayor dispersión?

La desviación estándar permite observar cuánto se alejan los valores de una variable respecto a su promedio.

Los valores obtenidos fueron:

Variable	Desviación estándar
Edad	19,99
Frecuencia cardíaca	15,91
Temperatura	0,95
Glucosa	39,29
Saturación	2,72

De acuerdo con los valores registrados, la glucosa presentó la mayor desviación estándar, con 39,29, seguida de la edad, con 19,99, y la frecuencia cardíaca, con 15,91.

Esto indica que los valores de glucosa presentaron una mayor variabilidad absoluta alrededor de su promedio dentro de la base de datos.

Interpretación:

La glucosa presentó la mayor desviación estándar, con 39,29, seguida de la edad, con 19,99. Esto indica que los valores de estas variables presentan una mayor dispersión absoluta respecto a sus respectivas medias. Por otra parte, la saturación presentó una desviación estándar de 2,72, lo que refleja una menor variabilidad absoluta en comparación con las demás variables.

Misión 5. Buscar pacientes por condiciones

¿Qué sucede al cambiar el valor de 100 por 95?

Al utilizar inicialmente un criterio de frecuencia cardíaca superior a 100, se seleccionaron 25 registros. Al disminuir el valor del criterio a 95, la cantidad aumentó a 48 registros.

Esto sucede porque, al disminuir el umbral, se incluyen más observaciones que cumplen la condición de presentar una frecuencia cardíaca superior a 95.

Interpretación:

La modificación del umbral cambia la cantidad de registros seleccionados. Cuanto menor es el valor establecido para esta condición, mayor puede ser el número de observaciones que cumplen el criterio.

Misión 6. Dos condiciones simultáneas

¿Qué sucede al modificar el umbral de saturación de 95 a 96?

Al establecer una saturación inferior a 95 y una frecuencia cardíaca superior a 100, se encontraron 5 registros que cumplían ambas condiciones.

Posteriormente, al modificar el umbral de saturación a un valor inferior a 96, el número de registros aumentó a 7.

¿Por qué cambia el resultado?

El resultado cambia porque al aumentar el límite de saturación de 95 a 96 se amplía el conjunto de registros que pueden cumplir esa condición. De esta manera, se incorporan dos registros adicionales que también presentan una frecuencia cardíaca superior a 100.

En el código se utilizó el operador `&`, que permite seleccionar únicamente los registros que cumplen simultáneamente las dos condiciones establecidas.

Misión 7. Crear una variable derivada: IMC

¿Cuál es el IMC promedio?

El índice de masa corporal (IMC) se calculó utilizando el peso y la estatura de cada registro mediante la siguiente fórmula:

IMC = Peso (kg) / Estatura² (m²)

El promedio obtenido para los 200 registros fue de **28,24 kg/m²**.

Interpretación:

El cálculo permitió crear una nueva variable a partir de dos datos que ya estaban presentes en la base de datos: el peso y la estatura. De esta manera, se obtuvo una variable derivada que posteriormente pudo utilizarse para describir la información.

Este resultado corresponde exclusivamente a un ejercicio educativo con datos sintéticos y no debe utilizarse para establecer diagnósticos individuales.

Misión 9. Histograma de edades

¿Qué intervalo de edades parece más frecuente?

El intervalo más frecuente (la moda visual) se ubica entre los 60 y 65 años aproximadamente, alcanzando el pico máximo de la distribución con más de 25 registros. Existe además un segundo pico relevante entre los 48 y 53 años.

Interpretación:

El histograma evidencia una distribución bimodal o con dos picos de mayor concentración (alrededor de los 50 y los 60 años), separados por un valle notable en la franja de los 53 a 59 años, donde la frecuencia desciende a su punto mínimo. Esta representación permite identificar que los registros no se distribuyen de forma uniforme, sino que se concentran principalmente en personas adultas de mediana y avanzada edad

Misión 10. Comparación por servicios

¿Qué servicio tiene más registros? La distribución de los registros por servicio fue la siguiente:

Servicio	Cantidad de registros
Observación	54
Hospitalización	51
Urgencias	50
Consulta externa	45
Total	**200**

El servicio con mayor cantidad de registros fue Observación, con 54, mientras que Consulta externa presentó la menor cantidad, con 45.

¿Hay diferencias en las medias? Se calcularon las medias de edad, frecuencia cardíaca y saturación para cada servicio:

Servicio	Edad promedio	FC promedio	Saturación promedio
Consulta externa	55,4	85,1	96,4
Hospitalización	55,2	86,3	96,9
Observación	48,9	79,0	95,9
Urgencias	50,6	79,3	96,1

Interpretación: Se observaron diferencias entre los promedios de los servicios. Consulta externa presentó la mayor edad promedio, con 55,4 años, mientras que Observación presentó la menor, con 48,9 años.

En cuanto a la frecuencia cardíaca, Hospitalización presentó el promedio más alto, con 86,3 latidos por minuto, mientras que Observación presentó el más bajo, con 79,0.

Respecto a la saturación, Hospitalización presentó el promedio más alto, con 96,9 %, y Observación el más bajo, con 95,9 %.

Estas diferencias describen la distribución de los datos dentro de cada servicio, sin que permitan establecer por sí solas una explicación clínica.

Misión 11. Construcción del reporte automático

Se elaboró un reporte educativo mediante Python, utilizando los resultados calculados a partir de la base de datos.

Los principales valores obtenidos fueron:

- Número de registros: 200.
- Edad promedio: 52,4 años.
- Frecuencia cardíaca promedio: 83,3 latidos por minuto.
- Saturación promedio: 96,3 %.
- Glucosa promedio: 140,1.
- Registros con frecuencia cardíaca superior a 100: 25.

El reporte se guardó en un archivo de texto denominado `reporte_educativo.txt`.

Interpretación:

La generación automática del reporte permitió reunir varios resultados estadísticos en un solo archivo, facilitando su consulta y organización. También permitió reconocer cómo Python puede utilizarse para automatizar tareas de procesamiento y presentación de información.

3. Desafío de cierre: misión 12

Registros de personas mayores de 60 años

Se aplicó un filtro para seleccionar los registros cuya edad fuera superior a 60 años.

El resultado fue de **78 registros**.

Interpretación:

De los 200 registros disponibles, 78 correspondieron a personas con edades superiores a 60 años. Este procedimiento permitió seleccionar un grupo específico de observaciones utilizando una condición establecida en Python.

Nueva gráfica de glucosa

Se elaboró un histograma de la variable glucosa para observar su distribución dentro de los registros.

Interpretación:

El histograma permitió visualizar la frecuencia con la que aparecen los diferentes intervalos de glucosa. Se observaron variaciones en la cantidad de registros entre los intervalos, lo que evidencia que los valores no se distribuyen de manera uniforme en toda la base de datos.

El promedio de glucosa obtenido fue de 140,1.

4. Tres conclusiones descriptivas

1. La base de datos estuvo conformada por 200 registros sintéticos y 12 variables. La edad promedio fue de 52,4 años, con valores comprendidos entre 18 y 88 años. Además, se identificaron 78 registros correspondientes a personas mayores de 60 años.
2. La frecuencia cardíaca promedio fue de 83,3 latidos por minuto y la saturación promedio fue de 96,3 %. También se observaron diferencias entre los promedios de estas variables al comparar los distintos servicios, siendo Hospitalización el servicio con mayor frecuencia cardíaca promedio.
3. La glucosa presentó un promedio de 140,1 y una desviación estándar de 39,29, lo que indica una variabilidad importante de sus valores dentro de los registros analizados. La elaboración del histograma permitió observar gráficamente la distribución de esta variable.

5. Preguntas conceptuales

1. ¿Qué función cumple GitHub?

GitHub es una plataforma que permite almacenar, organizar y compartir archivos y proyectos mediante repositorios. También facilita el seguimiento de los cambios realizados en los archivos y permite mantener diferentes versiones de un proyecto.

En este laboratorio se utilizó para almacenar la base de datos en formato CSV, el notebook de Google Colab y el reporte educativo generado durante el análisis.

2. ¿Qué función cumple Google Colab?

Google Colab es un entorno que permite escribir y ejecutar código Python desde un navegador, sin necesidad de instalar todo el entorno de programación en el computador.

En este laboratorio se utilizó para conectar la base de datos almacenada en GitHub, explorar sus variables, realizar cálculos estadísticos, aplicar filtros, elaborar gráficos y generar un reporte automático.

3. ¿Qué diferencia hay entre un dato y una interpretación clínica?

Un dato corresponde a un valor obtenido mediante una medición o registro. Por ejemplo, una frecuencia cardíaca de 110 latidos por minuto representa un dato numérico.

En cambio, una interpretación clínica requiere analizar ese resultado junto con otros elementos, como los antecedentes, síntomas, condiciones individuales y demás hallazgos del paciente. Por lo tanto, un dato aislado no es suficiente para establecer un diagnóstico o tomar una decisión clínica. Es necesario considerar el contexto completo y realizar una valoración adecuada.

6. Conclusión general

El desarrollo de este laboratorio permitió aplicar herramientas digitales para el manejo y análisis de datos mediante GitHub y Google Colab. A través de Python fue posible verificar la calidad de la información, calcular medidas estadísticas, seleccionar registros según condiciones específicas, crear nuevas variables y representar gráficamente diferentes resultados.

Además, la actividad permitió comprender la importancia de diferenciar entre la descripción estadística de una base de datos y su interpretación clínica. El uso de datos sintéticos facilitó el aprendizaje de estas herramientas sin comprometer información personal o real de pacientes. En general, el laboratorio mostró cómo las herramientas de programación y almacenamiento digital pueden apoyar la organización, el procesamiento y la presentación de información en el área de la ingeniería médica.